

Trabajo Práctico 1

Regresión e Introducción a la evaluación de modelos

72.75 — Aprendizaje Automático (Machine Learning)
Instituto Tecnológico de Buenos Aires

2026 Q2 · Defensa: 26/08/2026

Resumen

Se implementan modelos de regresión lineal y polinómica para predecir el costo anual de gastos médicos (**charges**) del dataset *Insurance Charges*, evaluados con validación cruzada de $k = 5$ folds. Todo el aparato de evaluación — partición train/test, k -fold, codificación *one-hot*, estandarizado, ecuación normal, expansión polinómica y Lasso por descenso por coordenadas — está implementado desde cero sobre `numpy`, sin `scikit-learn`, tal como pide el punto 2.2 del enunciado.

El modelo elegido para producción es una **regresión lineal de grado 1 sin regularizar**, con once características, que alcanza un **RMSE de test de 4.288,52 dólares**. Es, a la vez, el de **menor error de validación cruzada** entre las 15 configuraciones elegibles y el **más simple** de todo el espacio de búsqueda: ya no hay que elegir entre esas dos cosas. La regla de 1 error estándar lo confirma igual — es también la más simple de las 7 configuraciones indistinguibles del mínimo —, pero ya no es lo que decide.

Que el modelo más simple del espacio de búsqueda gane no es casualidad: tres de las once características — `fumador_obeso` (D-23) y las derivadas `edad_al_cuadrado` y `bmi_si_fuma` (D-27, D-28), construidas a partir del análisis exploratorio de la Clase 3 — capturan de forma explícita la curvatura y las interacciones no aditivas del dataset, y con ellas ni la expansión polinómica ni la regularización agregan nada. Es el resultado central de este trabajo, y se desarrolla en la sección 2.5.

Índice

1. Introducción teórica: separación train / validación / test	1
2. Punto 1 — Limpieza de datos	2
2.1. Distribución de las variables	2
2.2. Variables categóricas	3
2.3. Datos faltantes	3
2.4. Outliers	3
2.5. Las tres poblaciones de charges , y la característica que salió de ahí	4
2.6. Características y escalado	6
3. Puntos 2 y 3 — Implementación	7
3.1. El pipeline, de punta a punta	7
3.2. Cómo se separaron train y test, y por qué así	7
3.3. La regresión polinómica sigue siendo lineal en los parámetros	8
3.4. Regularización L_1	8
4. Punto 4 — Resultados	8
4.1. Dónde está el sobreajuste, y cómo se lo reconoce	10

5. Punto 5 — Las tres respuestas	12
5.1. ¿Qué modelo obtuvo menor error?	12
5.2. ¿Cuál se implementaría en una aplicación real?	12
5.3. ¿Qué RMSE se espera en datos nuevos?	13
5.4. Los once coeficientes del modelo de producción	14
5.5. Sensibilidad al número de folds: ¿y si k no fuera 5?	15
5.6. Dónde vive el error que queda	18
6. Limitaciones	19
7. Guion de la presentación (10 minutos)	21
A. Reproducibilidad	21

1. Introducción teórica: separación train / validación / test

El objetivo de un modelo de regresión no es ajustar bien los datos que ya vio, sino predecir bien datos que **todavía no vio**. Medir el error sobre el propio conjunto de entrenamiento no sirve para eso: el modelo ajusta sus parámetros exactamente para minimizar ese error, así que un RMSE de train bajo puede significar dos cosas radicalmente distintas — que el modelo capturó el patrón real, o que memorizó el ruido particular de esas 1070 filas. Sin un conjunto separado no hay forma de distinguir una cosa de la otra.

Por eso el trabajo separa tres roles, cada uno con un dato distinto y ninguno intercambiable:

- **Entrenamiento (train).** Ajusta los parámetros del modelo, es decir los coeficientes de la regresión.
- **Validación.** No participa del ajuste; se usa para **elegir entre modelos** — qué grado polinómico, qué valor de λ en Lasso. Es la vara con la que compiten las configuraciones.
- **Test.** Se toca **una única vez**, al final, después de que grado y λ ya están fijados. Estima el error que el modelo va a tener en producción, sobre datos genuinamente nuevos.

La razón por la que el test tiene que quedar intacto hasta el final es sutil pero central: en el momento en que su error se usa para decidir algo — elegir un hiperparámetro, comparar dos arquitecturas, hasta simplemente “mirarlo y probar de nuevo” — deja de ser una medida honesta del error de generalización y pasa a ser, de hecho, un segundo conjunto de validación. El número que reporta ya no dice cuánto va a fallar el modelo en el mundo real, sino cuánto se sobreajustó también al test. En este trabajo el conjunto de test (267 filas) se evaluó **tres** veces sobre la misma partición —antes de D-23, después de D-23 y después de D-27/D-28, según D-26 y D-29—, siempre después de fijar el modelo por validación cruzada, nunca antes: el test no participó de ninguna decisión de selección. Cada evaluación extra erosiona un poco esa independencia, y tres es más de lo que la doctrina de este mismo párrafo recomienda; el motivo y el costo se reconocen explícitamente en *Limitaciones*.

¿Por qué validación cruzada y no un único split? Con un solo split, el resultado depende de qué filas cayeron del lado de validación por azar: con 1070 datos de train, una partición particular puede favorecer o perjudicar a un modelo simplemente por cómo cayeron los outliers o los casos raros. La validación cruzada evita depender de una sola tirada. Se parte el train en 5 bloques de aproximadamente 214 filas cada uno y se repite el ciclo ajustar–validar 5 veces, dejando cada vez un bloque distinto afuera del ajuste. Así **cada dato valida exactamente una vez y entrena en las otras cuatro vueltas**, y el promedio de los 5 errores tiene mucha menos varianza que el error de un único split: la señal que importa —¿esta configuración generaliza

mejor que aquella? — deja de estar enmascarada por el ruido de qué le tocó a cada partición. Con un n chico como este esa reducción de varianza es decisiva; es la diferencia entre poder distinguir dos configuraciones o no.

2. Punto 1 — Limpieza de datos

2.1. Distribución de las variables

Antes de decidir nada sobre los datos hay que mirarlos. La Clase 3 ordena ese paso — estadísticas descriptivas más histogramas, juntos, porque «nos permiten entender mejor la distribución de los datos» y detectar valores anómalos — y la figura 1 lo hace para las siete variables de una vez.




Figura 1: Las siete variables. Arriba las cuatro numéricas, con histograma; abajo las tres categóricas, con frecuencias. El color codifica el rol de cada variable en el modelo. Las numéricas enteras (**age**, **children**) van con un bin por valor; las continuas (**bmi**, **charges**), con el ancho que da la regla de Freedman–Diaconis, que se apoya en el rango intercuartil y por lo tanto no se deja inflar por la cola de **charges**.

Tres cosas aparecen ahí que ninguna tabla de medias muestra, y cada una tiene su análogo literal en los ejemplos del deck:

- **age no es uniforme.** Hay 136 personas de 18 y 19 años, unas 2,4 veces lo que le tocaría a dos años cualesquiera. La media (39,2) no lo delata.
- **children es discreta, no continua:** seis escalones enteros. Es el caso del slide 35 —una variable que parecía continua y el histograma revela discretizada— cuya receta es tratarla como categórica. Se evaluó y se descartó; ver D-25.
- **charges no tiene un centro: tiene tres.** Asimetría +1,52 y lóbulos secundarios claros. Es el caso de los slides 36–38, y es el que cambió el modelo de este trabajo: se desarrolla en la sección siguiente.

Lo que *no* aparece también es resultado: ninguna variable muestra dos escalas superpuestas, así que no hay unidades de medida mezcladas que corregir (slide 39) —sólo escalas distintas que estandarizar, que es otra cosa y se trata más abajo.

2.2. Variables categóricas

El dataset tiene tres variables categóricas: **sex** (binaria), **smoker** (binaria) y **region** (cuatro categorías: *northeast*, *northwest*, *southeast*, *southwest*). Se codificaron con **one-hot** y no con codificación ordinal porque esta última le impone al modelo un orden y una distancia numérica que no existen en los datos: asignar 0, 1, 2, 3 a las regiones le estaría diciendo que *southwest* está más lejos de *northeast* que de *southeast* en algún sentido matemático, cuando la variable es puramente nominal.

Para **region** se generaron 4 dummies pero se **descartó una columna**, que queda como categoría de referencia absorbida en la ordenada al origen. Es la forma estándar de evitar la *dummy variable trap*: si las 4 dummies estuvieran todas presentes sumarían siempre 1, lo cual las hace linealmente dependientes de la columna constante del modelo y vuelve singular la matriz de diseño, de modo que $X^T X$ no se puede invertir para resolver por mínimos cuadrados.

Para las binarias alcanza con **una sola columna** (**sex=male**, **smoker=yes**) en lugar de dos: la segunda categoría es exactamente el complemento de la primera, así que agregarla sería la misma trampa de colinealidad, sólo que con dos categorías en vez de cuatro.

El codificador resultante produce 11 columnas: **age**, **bmi**, **children**, **fumador_obeso**, **edad_al_cuadrado**, **bmi_si_fuma**, **sex=male**, **smoker=yes**, **region=northwest**, **region=southeast**, **region=southwest**.

2.3. Datos faltantes

El dataset no tiene ningún valor nulo en las 1338×7 celdas originales. Sí apareció **una fila duplicada exacta** — los índices 195 y 581 son idénticos en las 7 columnas — que se eliminó, quedando 1337 filas.

La eliminación se hace **antes del split** train/test, y el motivo no es cosmético: un duplicado exacto repartido entre ambos conjuntos —una copia en train y la otra en test— filtraría información del test hacia el entrenamiento sin que el modelo tuviera que generalizar nada. El error de test quedaría artificialmente bajo para esa fila.

2.4. Outliers

Se comparó la detección por **rango intercuartílico (IQR)** contra **z-score**, y se optó por IQR. La tabla de discrepancia muestra por qué:

Tabla 1: Los dos criterios no coinciden, y la discrepancia se explica.

Variable	IQR detecta	Z-score detecta
charges	139 (10,4 %)	7
children	0	18

En **charges**, el z-score detecta muchísimo menos porque su propia definición depende de la media y el desvío estándar, y **charges** tiene una asimetría de 1,516: los valores extremos —que son justamente los que se querría detectar— arrastran la media hacia arriba e **inflan el desvío estándar**, con lo cual “tres desvíos de la media” deja de ser un umbral exigente. Los propios outliers se disfrazan a sí mismos. El IQR, al basarse en cuartiles, es robusto a esa distorsión.

En **children** pasa lo inverso: el z-score marca 18 valores y el IQR ninguno, porque **children** es un entero acotado entre 0 y 5, y “estar a tres desvíos de la media” no significa lo mismo en una variable discreta de rango chico que en una continua sin cota.

Los outliers se conservan. De los 139 outliers de **charges** detectados por IQR, el **97,8 % son fumadores**, contra apenas 11,5 % de fumadores en el resto de la población. Esa desproporción es la evidencia de que **no son errores de carga, son una subpoblación real**: fumar

dispara el costo médico de forma no lineal, y esos 139 casos son la cola derecha esperable de esa subpoblación, no ruido. Eliminarlos le escondería al modelo justo el fenómeno más importante del dataset.




Figura 2: Arriba: de dónde sale el criterio. La caja va de Q_1 a Q_3 —el 50 % central— y su ancho es el IQR; el corte está una caja y media más a la derecha. Abajo: quiénes quedan de ese lado, con la misma distribución apilada por condición de fumador. Los dos paneles comparten el eje horizontal, así que el umbral punteado es una sola vertical que los cruza. La cola larga por encima del corte es *casi enteramente* de fumadores (97,8 %), que es el argumento para conservarla.

2.5. Las tres poblaciones de charges, y la característica que salió de ahí

El histograma de **charges** muestra un pico grande y dos jorobas a la derecha. La Clase 3 no se queda en constatarlo: cuando aparece un segundo pico, prescribe (a) darle esa información al sistema como variable binaria o (b) partir el dataset y entrenar dos modelos, y antes de decidir, «ver el histograma separado para cada población para ver si realmente son distintas». La figura 3 es ese paso.




Figura 3: Arriba, *charges* sin separar. Abajo, el mismo histograma con los mismos bins, partido por población. Las medianas son \$7.346, \$20.201 y \$40.918.

Son tres, y no se separan igual de bien. El grupo de fumadores con $\text{bmi} \leq 30$ se solapa con la cola de los no fumadores; el de fumadores con $\text{bmi} > 30$ arranca en \$32.548, por encima del 99,2 % de todos los demás.

Es un escalón, no una pendiente. La distinción decide qué hacer. Partiendo el *bmi* en tramos finos alrededor de 30, entre los fumadores el costo medio salta de \$23.555 en el tramo [29, 30) a \$38.799 en el [30, 31) —unos quince mil dólares en una unidad de *bmi*—, con pendiente suave a los dos lados del corte; entre los no fumadores el mismo corte casi no mueve nada (\$8.257 contra \$8.058). Si fuera una pendiente, los saltos entre tramos contiguos serían todos parecidos.

Eso importa porque la expansión polinómica de grado 2 *ya* genera el término $\text{bmi} * \text{smoker} = \text{yes}$, y el modelo lo conserva con peso +3,317. Pero un producto con una variable continua sólo puede representar un cambio de pendiente: no puede representar un salto. Por eso se agrega la característica binaria

$$\text{fumador_obeso} = (\text{smoker} = \text{yes}) \wedge (\text{bmi} > 30),$$

que es la opción (a) del deck (decisión D-23). El umbral 30 es el de la OMS: es una constante médica, externa a este dataset, y esa procedencia es lo que hace legítimo usarla —no sale de buscar cuál corte minimiza el error. El barrido de umbrales lo confirma igual: el mínimo cae exactamente en 30, con 29 y 31 claramente peores.

No es fuga de datos: las dos columnas de las que sale están disponibles al momento de predecir y *charges* no interviene en el cálculo. Y el efecto es de la *interacción*, no de sus partes: agregar sólo $\text{bmi} > 30$ deja el error prácticamente donde estaba.

2.6. Características y escalado

El enunciado pide dos decisiones justificadas, y van por separado.

Qué características se incluyen: las seis originales, sin descartar ninguna, más dos derivadas. El enunciado admite explícitamente que “pueden ser todas”, y en este dataset esa es además la respuesta correcta para las seis variables crudas. A ellas se suman `edad_al_cuadrado` (D-27) y `bmi_si_fuma` (D-28), que la tabla documenta junto con las demás porque son la otra mitad de esta misma decisión: no alcanza con no tirar nada, también hay que agregar lo que la estructura del dataset pide (`fumador_obeso` ya se presentó en la sección 2.5 con la misma lógica):

Tabla 2: Decisión de inclusión, variable por variable.

Variable	¿Se incluye?	Por qué
<code>age</code>	Sí	Segunda correlación más alta con <code>charges</code> (0,299) y relación monótona clara. En el modelo de producción queda con coeficiente 45,10.
<code>bmi</code>	Sí	Correlación baja (0,198) pero no descartable: su efecto depende de <code>smoker</code> , y Pearson mide relación lineal, no interacciones. Coeficiente 111,20.
<code>children</code>	Sí	Correlación 0,068, la más débil. Se conserva igual: es barata, y en el modelo de producción (lineal, sin regularizar) queda con coeficiente 815,02.
<code>sex</code>	Sí	Binaria, una columna. El modelo de producción no regulariza, así que no hay penalización que la apague: queda con coeficiente $-218,32$ (<code>sex=male</code>), de los más chicos en magnitud entre los once, pero no nulo.
<code>smoker</code>	Sí	La variable más informativa del dataset (correlación 0,787).
<code>region</code>	Sí	Tres columnas tras el one-hot. Aporta poco, pero es la única variable geográfica y su costo es mínimo.
<code>edad_al_cuadrado</code>	Sí	Derivada (D-27): captura la <i>curvatura</i> del costo con la edad, que un término lineal en <code>age</code> no puede representar. Coeficiente 3749,13, el tercero más grande de los once.
<code>bmi_si_fuma</code>	Sí	Derivada (D-28): captura la <i>pendiente</i> del <code>bmi</code> , distinta entre fumadores y no fumadores. Coeficiente 5236,99, el más grande de los once.

Advertencia de interpretabilidad. Agregar `edad_al_cuadrado` y `bmi_si_fuma` tiene un costo. `edad_al_cuadrado` es, literalmente, una función determinista de `age`, y `bmi_si_fuma` lo es de `bmi` dentro del grupo de fumadores: están muy correlacionadas entre sí. Por eso los coeficientes de `age` y `bmi` cayeron tan fuerte respecto de la versión anterior del pipeline (`age`: de 3754 a 45,10; `bmi`: de 333 a 111,20), y el de `smoker=yes` también bajó (de 5437 a 1161,22): las derivadas absorbieron buena parte del efecto que antes cargaba la variable original. Eso no significa que `age` o `bmi` dejaron de importar — significa que, dentro de cada grupo (`age` con `edad_al_cuadrado`; `bmi`, `smoker=yes` y `fumador_obeso` con `bmi_si_fuma`), los coeficientes individuales ya no son interpretables por separado: sólo tiene sentido leerlos como grupo. Es un costo real de interpretabilidad a cambio de mejor ajuste.

El criterio general es que **no se descarta ninguna variable a mano**. Con 1337 filas y sólo

11 columnas tras codificar no hay problema de dimensionalidad que lo justifique, y sacar una variable mirando su correlación con el objetivo es una decisión tomada *con los datos*, exactamente el tipo de elección que después contamina la evaluación. La selección de variables se delega a la penalización L_1 , que la hace **dentro de cada fold** y por lo tanto sin fuga.

El escalado. Las variables numéricas se **estandarizan** (media 0, desvío 1) antes de ajustar cualquier modelo con regularización, porque Lasso penaliza la magnitud de los coeficientes: si las variables están en escalas distintas —age en años, bmi en kg/m², children en unidades enteras chicas— la penalización castiga más a los coeficientes de las variables que naturalmente necesitan valores grandes, sin que eso tenga que ver con su importancia real.

El punto crítico es **cuándo** se calculan la media y el desvío: **siempre sobre el fold de entrenamiento únicamente**, nunca incluyendo el fold de validación. Es la misma lógica que con el test. Si se calcularan sobre todos los datos, la validación dejaría de ser una medición honesta, porque el escalado ya habría “visto” esos datos antes de que el modelo intentara predecirlos.

3. Puntos 2 y 3 — Implementación

3.1. El pipeline, de punta a punta

1. quitar_duplicados: 1338 $\rightarrow$ 1337 filas.
2. agregar_derivadas: agrega tres columnas —fumador_obeso (D-23), edad_al_cuadrado (D-27) y bmi_si_fuma (D-28)—. Ocurre **antes del split**, porque las columnas de las que salen ya están disponibles para cualquier fila y ninguna usa charges.
3. separar_train_test con semilla 42: 1070 filas de train, 267 de test (80/20).
4. CodificadorCategoricas, ajustado **sólo con train**: produce las 11 columnas descriptas arriba.
5. k_fold: partición propia en 5 folds sobre el train.
6. Dentro de cada fold: Estandarizador (ajustado sólo con el fold de entrenamiento) $\rightarrow$ expandir_polinomial $\rightarrow$ Estandarizador otra vez $\rightarrow$ ajuste del modelo.
7. Modelos: RegresiónLineal (mínimos cuadrados vía descomposición en valores singulares) y Lasso (descenso por coordenadas con actualización incremental del residuo).

3.2. Cómo se separaron train y test, y por qué así

El procedimiento concreto es: se genera una **permutación aleatoria** de los índices 0...1336 y se corta, mandando las últimas $\text{round}(1337 \times 0,2) = 267$ posiciones a test y las 1070 restantes a train. Tres decisiones dentro de eso:

- **Se baraja antes de cortar.** Tomar las últimas 267 filas del archivo tal como viene sería válido sólo si el orden fuera aleatorio, y eso no se puede dar por sentado: los CSV suelen venir ordenados por algún criterio. Barajar rompe cualquier estructura latente en el orden.
- **La semilla es fija (42).** Sin semilla fija ningún número de este informe sería reproducible. También evita una trampa sutil: si la semilla variara, sería posible correr varias veces y quedarse con la partición que da mejores números, que es una forma encubierta de ajustar contra el test.
- **No se estratifica —y el motivo cambió (D-24).** La versión previa de este informe decía que no hay clases que preservar porque el objetivo es continuo. El análisis exploratorio de la Clase 3 lo refuta: charges no es una distribución continua unimodal sino *tres poblaciones casi disjuntas* (figura 3), y los cinco folds reparten la tercera de forma desigual —entre 17 y 31 personas, del 7,9 % al 14,5 %—, con correlación +0,62 entre esa proporción y el charges medio del fold. Hay clases de facto, y se reparten mal.

Lo que ocurre es que estratificar por ellas *no cambia nada*, y eso se midió: promediando sobre ocho particiones, el desvío del RMSE entre folds es 593 con folds aleatorios y 591 con folds estratificados —dos dólares, cuando entre dos particiones del mismo método la diferencia va de 410 a 715—. Lo que mueve el error de un fold no es cuántos fumadores obesos le tocaron sino cuáles: dentro de ese grupo los costos van de \$32.548 a \$63.770 (sobre el dataset completo, como todo el EDA del punto 1), así que igualar los conteos deja intacta la varianza que importa. La estratificación controla justo la dimensión que no era el problema. La decisión se sostiene; su justificación es ahora una medición y no una definición equivocada.

- **Sí sigue valiendo el resto.** No hay estructura temporal ni de grupos —cada fila es una persona distinta— así que el supuesto de independencia que justifica el barajado se cumple.

3.3. La regresión polinómica sigue siendo lineal en los parámetros

Elevar `age` al cuadrado o multiplicar `bmi` por `smoker=yes` no cambia la naturaleza del modelo: sigue siendo una combinación lineal de columnas de la matriz de diseño, sólo que esas columnas ahora son transformaciones no lineales de las variables originales. Lo que se ajusta por mínimos cuadrados es exactamente el mismo problema que con grado 1; lo único que cambia es qué características se le presentan al modelo.

3.4. Regularización L_1

El objetivo que minimiza el Lasso implementado es

$$J(w) = \frac{1}{2n} \|y - Xw - b\|_2^2 + \lambda \|w\|_1, \quad (1)$$

resuelto por descenso por coordenadas con *soft-thresholding*. El intercepto b no se penaliza: se obtiene centrando X e y y recuperándolo como $b = \bar{y} - \bar{x}^T w$. Penalizarlo encogería la predicción media hacia cero, que no es lo que la regularización busca.

La grilla de λ se construye **relativa a $\lambda_{\text{máx}}$** , el menor valor que anula todos los coeficientes:

$$\lambda_{\text{máx}} = \max_j \frac{|x_j^T (y - \bar{y})|}{n}. \quad (2)$$

Ese máximo se calcula sobre el train completo, y da 10360,94 —el mismo valor para los grados 2, 3 y 4—. Una grilla relativa es interpretable y comparable entre grados; una absoluta elegida a ojo, no.

4. Punto 4 — Resultados

Tabla 3: Validación cruzada de 5 folds sobre las 1070 filas de entrenamiento. Regresión lineal sin regularizar, por grado del polinomio. Tabla generada por `src/tablas.py` a partir de `resultados/cv_lineal.csv`.

Grado	RMSE train	RMSE validación	Características
1	4351,6 ± 93,2	4413,4 ± 367,0	11
2	4227,2 ± 104,7	4516,7 ± 380,0	77
3	3931,1 ± 117,1	6757,5 ± 857,0	363
4	3379,1 ± 105,3	87916,9 ± 47000,1	1364

Tabla 4: Lasso, mismo esquema de validación cruzada. Las configuraciones que no convergieron quedan excluidas de la selección (D-20). Tabla generada por `src/tablas.py` a partir de `resultados/cv_lasso.csv`.

Grado	λ	RMSE train	RMSE validación	Coefs. $\neq 0$
2	3108,28	6369,5	6397,0	4,4
2	1036,09	4711,7	4730,3	5,8
2	310,83	4408,7	4434,0	9,4
2	103,61	4330,4	4422,9	22,2
2	31,08	4288,7	4459,2	37,4
3	3108,28	6363,7	6390,7	4,2
3	1036,09	4711,0	4730,1	5,4
3	310,83	4389,3	4431,4	15,6
3	103,61	4260,7	4464,4	48,8
3	31,08	4152,0	4621,8	96,0
4	3108,28	6363,4	6394,4	4,2
4	1036,09	4709,9	4732,4	5,6
4	310,83	4378,6	4433,7	17,0
4	103,61	4183,2	4531,6	74,2
4	31,08	3942,5	4938,2	166,6

4.1. Dónde está el sobreajuste, y cómo se lo reconoce




Figura 4: El error de entrenamiento baja monótonamente con el grado; el de validación toca fondo en grado 1 y después sube, hasta dispararse en grado 4. El eje está *partido*: el grado 4 se va a 87.916,9 dólares y en una escala única aplastaría a los otros tres hasta volverlos ilegibles. La banda es ± 1 desvío entre folds.

En regresión lineal sin regularizar el sobreajuste empieza ya en grado 2 y se vuelve catastrófico en grado 4. El error de **train** baja monótonamente (4351,6 $\rightarrow$ 4227,2 $\rightarrow$ 3931,1 $\rightarrow$ 3379,1 dólares), porque más características siempre le dan al modelo más grados de libertad para ajustar lo que ya vio. El de **validación** hace exactamente lo contrario desde el arranque: toca su mínimo en grado 1 (4413,4) y sube en cada grado siguiente, hasta 87916,9 en grado 4 —**19,9 veces** el del grado 1—.

Por qué el grado 4 se dispara así. No es sólo que sobreajuste: es que el problema deja de estar determinado. La expansión de grado 4 sobre once características da **1364 columnas**, y el diagnóstico de rango que corre `src/experimentos.py` muestra que su rango efectivo es 436: el **68,0 %** de las columnas son combinación lineal exacta de las otras (las causas están en *Limitaciones*). Una de esas causas es nueva desde que se agregaron `edad_al_cuadrado` y `bmi_si_fuma`: a partir de grado 2 la propia expansión polinómica las **duplica exactamente** —`age` $\times$ `age` vuelve a calcular `edad_al_cuadrado`, y `bmi` $\times$ `smoker=yes` vuelve a calcular `bmi_si_fuma`—, y esa duplicación es buena parte de por qué la redundancia sube al 68 % y por qué esta vez son **cuatro** las configuraciones que no convergen, no dos. En grado 1, que es el de producción, la duplicación no existe: cada característica aparece una sola vez. Con 856 filas por fold de entrenamiento, el ajuste de mínimos cuadrados sobre ese espacio es una extrapolación, y lo que predice fuera del fold no tiene por qué parecerse a nada.

El indicador más claro de sobreajuste no es sólo que el RMSE de validación suba, sino que la **brecha** entre train y validación crezca sistemáticamente: de **61,8 dólares** en grado 1 a **84.537,9 dólares** en grado 4. Un modelo que generaliza bien tiene un error de validación parecido al de train; una brecha que se ensancha es la firma directa de que el modelo está aprendiendo particularidades del fold de entrenamiento que no se sostienen fuera.

El segundo indicador, más sutil pero igual de contundente, es la **estabilidad entre folds**: el desvío del RMSE de validación pasa de $\pm 367,0$ en grado 1 a $\pm 47,000,1$ en grado 4, **128 veces más grande**. Eso dice algo distinto de “el modelo es peor en promedio”: dice que el modelo de grado 4 es **inestable**, que su desempeño cambia drásticamente según qué filas caen en cada partición.

Una observación sobre el desvío en grado 1. Los $\pm 367,0$ del modelo elegido son más altos que los $\pm 355,3$ que daba el mismo grado 1 antes de D-23, y eso no es un defecto: es la contracara del hallazgo. Al capturar el escalón de **fumador_obeso**, el modelo elimina el error sistemático que dominaba antes, y lo que queda es el error idiosincrásico de los casos extremos —cuya repartición entre folds es justamente lo que varía—. Es el mismo fenómeno que explica por qué estratificar no ayuda (D-24).




Figura 5: Camino de regularización. Al aflojar λ entran más características (panel inferior) y el error primero baja y después vuelve a subir. El tono codifica el grado del polinomio: más oscuro, grado más alto.

Lasso corrige el problema en buena medida: el mejor λ de grado 4 que efectivamente converge ($\lambda = 310,83$) lleva el RMSE de validación de 87916,9 a 4433,7 dólares —prácticamente

las mismas 19,9 veces de distancia que separan al grado 4 sin regularizar del grado 1, pero recorridas en el sentido contrario— dejando vivos 17,0 de los 1364 coeficientes en promedio. Que la penalización L_1 recupere de un espacio degenerado un error comparable al del modelo lineal simple es exactamente lo que la regularización promete, y acá se ve en su forma más extrema.

Lo que *no* logra es superarlo: el mejor Lasso de toda la tabla (grado 2, $\lambda = 103,61$) queda en 4422,92, apenas nueve dólares por encima del lineal de grado 1, con 22,2 características vivas en promedio en lugar de 11. Sobre esa comparación decide el punto siguiente.

5. Punto 5 — Las tres respuestas

5.1. ¿Qué modelo obtuvo menor error?

El de menor RMSE de validación cruzada es, directamente, **la regresión lineal de grado 1 sin regularizar**: RMSE de validación = $4413,45 \pm 366,97$, con las once características de grado 1, todas vivas. El mejor Lasso de toda la búsqueda (grado 2, $\lambda = 103,61$) queda apenas nueve dólares por encima, en 4422,92, con 22,2 coeficientes vivos en promedio.

5.2. ¿Cuál se implementaría en una aplicación real?

El mismo modelo que ganó la sección anterior, y esta vez la pregunta se responde sola: no hay que elegir entre el de menor error y el más simple porque son la misma configuración.

De todos modos vale correr el procedimiento completo, para no decidir por comodidad. Aplicando la **regla de 1 error estándar** sobre el ganador,

$$ES = \frac{366,97}{\sqrt{5}} = 164,11, \quad \text{umbral} = 4413,45 + 164,11 = 4577,56, \quad (3)$$

de las 19 configuraciones corridas, **cuatro** no convergieron y quedan fuera de la comparación (D-20): Lasso de grado 3 con $\lambda = 310,83$, $\lambda = 103,61$ y $\lambda = 31,08$, y Lasso de grado 4 con $\lambda = 31,08$. Sobre las 15 configuraciones elegibles que quedan, **7 caen por debajo del umbral**. Esas 7 son, para los datos disponibles, **indistinguibles entre sí**: cuál aparece primera en la tabla depende del azar de cómo cayó la partición en 5 folds, no de una diferencia real de capacidad predictiva.

Frente a un empate estadístico, lo habitual sería resolver por la configuración **más simple** del grupo empatado. Ese paso, esta vez, es innecesario: la más simple de las 7 —once características, grado 1, sin regularizar, sin ningún hiperparámetro que ajustar, y por lejos la de menos columnas en la matriz de diseño— **ya es** la que tiene el menor error de validación cruzada de toda la búsqueda. La regla de 1 ES no decide nada acá: sólo **confirma** lo que el mínimo ya decía. Y como ganador de la CV y modelo de producción son, por primera vez, el mismo modelo, el costo de la simplicidad es **0,00dólares**: no hay nada que sacrificar a cambio de un modelo más simple.

Vale subrayar lo que eso significa, porque es el resultado central del trabajo: *con las características correctas, ni la expansión polinómica ni la regularización compran nada*. Las dos existen para darle al modelo la flexibilidad de representar relaciones que las variables crudas no representan; una vez que `fumador_obeso`, `edad_al_cuadrado` y `bmi_si_fuma` las representan de forma explícita, la flexibilidad extra sólo agrega varianza. Antes de D-23 el mismo procedimiento elegía Lasso de grado 2 con 44 características, porque sin esas columnas derivadas el modelo lineal *sí* se quedaba corto (6122,8 de RMSE de validación).

Tabla 5: Historia del RMSE de test a medida que el pipeline sumó características derivadas. Desde D-27/D-28, ganador de la CV y modelo de producción son el mismo modelo: no hay una fila separada que reportar para cada uno. Las dos filas intermedias son registro de los pipelines anteriores, verificable y no una afirmación (D-26).

Modelo	Característ
Producción = ganador de la CV (lineal grado 1)	
<i>Producción entre D-23 y D-27/D-28</i> (lineal grado 1, sin <code>edad_al_cuadrado</code> ni <code>bmi_si_fuma</code>)	
<i>Producción anterior a D-23</i> (Lasso grado 2, $\lambda = 286,4$)	
Baseline: predecir siempre la media	

En tres pasos el RMSE de test bajó de 4.739,33 a 4.465,32 y a 4.288,52: **450,81 dólares menos, un 9,5 %** sobre el punto de partida. La primera mejora vino de `fumador_obeso` (D-23); la segunda, de sumar `edad_al_cuadrado` y `bmi_si_fuma` (D-27, D-28). Ninguna de las dos vino de agregar grados de libertad al polinomio ni de ajustar un hiperparámetro de regularización: las tres características derivadas son la mejora completa.

5.3. ¿Qué RMSE se espera en datos nuevos?

4.288,52 dólares — el RMSE de **test** del modelo de producción,
no su RMSE de validación (4.413,45).

Es importante entender por qué el número de validación está sesgado a la baja y no se puede prometer. Esa configuración se eligió por tener, directamente, el RMSE de validación **más bajo** de las 15 estimaciones elegibles (de 19 corridas; cuatro quedaron fuera por no converger). Cada una de esas estimaciones tiene ruido de muestreo, porque es un promedio sobre sólo 5 folds. Cuando se elige el **mínimo** de un conjunto de estimaciones ruidosas, ese mínimo queda sesgado hacia abajo *aunque cada estimación individual sea insesgada*: es más probable que el “ganador” lo sea en parte por haber tenido una racha favorable de ruido, no sólo por ser mejor de verdad. Acá ese argumento aplica de lleno y sin salvedades —no hay un modelo elegido por simplicidad y otro que ganó la CV: hay uno solo, y es exactamente el mínimo de la tabla—. El test, al no haber participado de ninguna decisión, no tiene ese sesgo.

Y sin embargo el test dio *mejor* que la validación: 4.288,52 contra 4.413,45, una diferencia de $-124,93$ dólares. Eso no contradice el argumento anterior: el sesgo de selección predice que el test tienda a ser peor *en promedio*, no que lo sea en esta partición puntual, y 124,93 dólares es chico frente al $\pm 366,97$ de ruido que ya separaba a los folds entre sí durante la validación. Con una sola partición de test no hay forma de saber si el ruido jugó a favor esta vez o si el sesgo es de verdad más chico de lo que la teoría sugiere.

Dos advertencias que corresponde dar junto con ese número.

- El conjunto de test tiene **267 filas**. El 4.288,52 es en sí mismo una estimación con su propia incertidumbre de muestreo, que este trabajo no cuantificó con un intervalo de confianza. No hay que leerlo con cuatro decimales.
- El RMSE **promedia sobre una población heterogénea**. El error no se reparte parejo: se concentra en los fumadores, que son los casos más caros y los que más le importa acertar a una aseguradora. Prometer un único RMSE global oculta esa asimetría.




Figura 6: Predicho contra real sobre el conjunto de test. El modelo acierta con precisión en la mayoría barata (nube azul sobre la diagonal) y se dispersa en los casos caros, que son casi todos fumadores: es la asimetría del error que la segunda advertencia menciona.

5.4. Los once coeficientes del modelo de producción

Tabla 6: El modelo entero. Son las once características de grado 1, sin penalización: no hay selección que reportar porque no hay nada de más que apagar. Los coeficientes están sobre características estandarizadas, así que sus magnitudes son comparables entre sí —con una salvedad importante: `age` y `edad_al_cuadrado` son función determinista una de la otra, y lo mismo `bmi`, `smoker=yes` y `bmi_si_fuma` entre sí. Dentro de cada uno de esos grupos colineales el coeficiente individual no se interpreta solo: hay que leer el grupo completo (ver *Advertencia de interpretabilidad*, más arriba).

Característica	Coeficiente
<code>bmi_si_fuma</code>	5236,99
<code>fumador_obeso</code>	4891,83
<code>edad_al_cuadrado</code>	3749,13
<code>smoker=yes</code>	1161,22
<code>children</code>	815,02
<code>region=southwest</code>	−498,36
<code>region=southeast</code>	−424,86
<code>sex=male</code>	−218,32
<code>region=northwest</code>	−142,53
<code>bmi</code>	111,20
<code>age</code>	45,10

El hallazgo. Los tres coeficientes más grandes del modelo son, en orden, las tres características derivadas: `bmi_si_fuma` (5236,99), `fumador_obeso` (4891,83) y `edad_al_cuadrado` (3749,13), las tres por encima de `smoker=yes` (1161,22), que en el modelo original era el término dominante. El modelo dice, leído en orden: la pendiente del `bmi` entre fumadores es lo que más pesa; ser fumador *y* obeso suma otro tanto encima; la curvatura de la edad importa casi tanto como las dos anteriores; y recién después aparece el efecto de fumar por sí solo, ya reducido porque buena parte de lo que hacía antes —la pendiente distinta según el `bmi`— ahora lo explica `bmi_si_fuma` de forma directa. Es el mismo fenómeno que la advertencia de interpretabilidad ya

anticipaba: las características derivadas no compiten con las originales por espacio en el modelo, les *absorben* el efecto.

Vale la pena contrastarlo con lo que hacía el modelo anterior a D-23. Ahí la penalización L_1 dejaba vivas 10 de 44 características y el término `bmi*smoker=yes` quedaba tercero en magnitud, por encima de `bmi` sola: *el Lasso había encontrado la interacción por su cuenta*, sin que nadie se la indicara. Ese resultado sigue en pie y es una buena demostración de para qué sirve L_1 —pero encontraba la interacción en la única forma que su espacio de características le permitía, como un cambio de pendiente. El análisis exploratorio mostró que la forma correcta era un escalón, y darle esa columna directamente al modelo resultó valer más que toda la maquinaria que la aproximaba.




Figura 7: La interacción, cuantificada. Ajustando una recta por grupo, la pendiente es de **83 dólares por unidad de BMI** entre los no fumadores y de **1473** entre los fumadores: un factor de **17,7**. Un modelo puramente aditivo sobre las variables crudas no puede representar esa diferencia; `fumador_obeso` sí, y con un solo coeficiente.

5.5. Sensibilidad al número de folds: ¿y si k no fuera 5?

Toda la sección anterior descansa sobre $k = 5$. Conviene preguntarse cuánto de la respuesta es del modelo y cuánto es de esa elección.

Estado de esta sección tras D-27/D-28. El barrido controlado con la configuración de producción fija —la figura 8 y todo lo que se dice sobre ella— está **rehecho** con las once características vigentes (cuesta minutos, no horas: `resultados/sensibilidad_k.csv`). La **selección completa** —las 19 configuraciones, en $k = 5, 10$ y 20 , la tabla de más abajo— **no**: correrla sobre las 1364 columnas del grado 4 cuesta unas 5 horas por cada valor de k , y no se volvió a pagar ese costo porque la corrida más reciente disponible —con el pipeline de **nueve** características, posterior a D-23 y anterior a D-27/D-28— ya mostraba que el modelo de producción no se movía con k ; queda preservada en `resultados/sensibilidad_k.json` y, con el mismo contenido bajo otro nombre desde que D-27/D-28 la dejó atrás, en `sensibilidad_k_previo_d27.json`. La tabla de más abajo es todavía una generación anterior a esa: el pipeline de **ocho** características, previo a D-23, preservado en `sensibilidad_k_previo_d23.json`. Su conclusión —el modelo de producción no se mueve con k — es la que las dos corridas posteriores vinieron a confirmar, no a poner en duda.

Nada de esto vuelve a tocar el test. El módulo `src/sensibilidad_k.py` rehace el mismo split con la misma semilla y descarta `idx_test` sin usarlo: todo ocurre dentro de las 1070 filas de train. No re-evalúa el test —lo que violaría la doctrina de la sección anterior— sino que mide cuán estable es un procedimiento de selección que ya se ejecutó.

La pregunta que importa: ¿cambia el modelo elegido? Se repitió la selección completa —las 19 configuraciones, la regla de 1 error estándar, el criterio de parsimonia— con $k = 5, 10$ y 20.

Tabla 7: La selección del punto 5, recalculada con tres valores de k —en el pipeline anterior a D-23, ocho características, ver el recuadro—. La última fila es la respuesta: el modelo de producción no se mueve.

	$k = 5$	$k = 10$	$k = 20$
Filas de entrenamiento por fold	856	963	1016
Ganador crudo de la CV	lasso g4, $\lambda=286,4$	lasso g4, $\lambda=95,5$	lasso g4, $\lambda=95,5$
RMSE de validación del ganador	4920,0	4833,2	4744,8
Error estándar $\sigma/\sqrt{k}$	100,3	229,2	230,7
Configuraciones dentro de 1 ES	8	9	9
Producción (regla de 1 ES)	lasso grado 2, $\lambda = 286,37$ — en los tres		

El modelo de producción es idéntico en los tres casos. La respuesta del punto 5 no es un artefacto de haber puesto 5.

Dos cosas sí se mueven, y conviene declararlas. El **ganador crudo** cambia de λ , y el que queda solo es $k = 5$: con 856 filas por fold el grado 4 necesita más regularización que con 963 o 1016. Es el sesgo de la curva de aprendizaje, medible y no teórico —aunque irrelevante para lo que se entrega, porque el ganador crudo no es el modelo de producción—. Y la **banda de 1 ES se ensancha**: de 8 a 9 configuraciones indistinguibles.

Qué le pasa a los dos números que reporta este informe. Fijando la configuración de producción y variando sólo k —para que la única causa de las diferencias sea k — aparecen dos hallazgos distintos, y el primero corrige una lectura tentadora.

Sensibilidad al número de folds — configuración de producción fija (lineal grado 1, sin regularización)




Figura 8: Sensibilidad al número de folds, con la configuración de producción fija (lineal grado 1, sin regularizar, once características). Los ocho valores de k dejan folds de 214, 107, 54, 21, 11, 5, 2 y 1 punto. **Arriba:** el nivel del error casi no depende de k —la curva agrupada va de 4428,7 a 4405,9, un 0,51 %—; lo que se desploma es la *forma de promediarlo*, y el área sombreada entre las dos curvas es ese sesgo. **Abajo:** el error estándar sí depende de k , con un máximo de 293,9 en $k = 10$ y una caída posterior; el $k = 5$ del informe vale 164,1. La banda gris marca dónde los folds son tan chicos que σ deja de medir dispersión entre remuestreos.

Primero: la caída del RMSE es un artefacto de la métrica, no del modelo. El pipeline reporta la *media de los k RMSE de fold*, y esa media baja 2064,9 dólares (4413,4 → 2348,5) al ir de $k = 5$ a LOO. Es tentador leerlo como que $k = 5$ es fuertemente pesimista, pero no lo es: la raíz es cóncava, así que por desigualdad de Jensen

$$\text{media}_i \sqrt{\text{ECM}_i} < \sqrt{\text{media}_i \text{ECM}_i}, \quad (4)$$

con una brecha que crece a medida que los folds se achican. Calculando en cambio el **RMSE agrupado** —una sola raíz sobre los 1070 residuos *out-of-fold* juntos, que no tiene ese sesgo— el error va de 4428,7 a 4405,9: **22,8 dólares, un 0,51 %**, y agotados ya en $k = 20$. El sesgo pesimista real de $k = 5$ es despreciable.

Ese mismo fenómeno, llevado al extremo, es lo que vuelve inservible a *leave-one-out* con este pipeline: con un solo dato por fold $\text{RMSE}_i = |y_i - \hat{y}_i|$, y el promedio de los k RMSE **es literalmente el MAE** (2348,5) —un 46,7 % por debajo del RMSE agrupado del mismo k (4405,9), y no comparable contra el RMSE de test de este informe—. LOO no es «más validación»: rompe la métrica en silencio, además de exigir ajustar cada configuración 1070 veces en lugar de 5.

Segundo: el error estándar tiene un único pico, en $k = 10$, y no una meseta. Midiendo la grilla densa — $k = 5, 10, 20, 50, 100, 200, 500, 1070$ — el ES sube de 164,1 en $k = 5$ a un máximo de 293,9 en $k = 10$, y de ahí cae de forma monótona: 250,9 / 249,3 / 231,6 / 201,3

/ 152,8 / 114,0 hasta LOO. No hay meseta entre $k = 10$ y $k = 50$: el pico está en un solo punto y la curva ya está bajando en $k = 20$.

El mecanismo se verifica contra los propios datos: si σ (el desvío del RMSE entre folds) creciera exactamente como $\sqrt{k}$, el ES sería constante. De $k = 5$ a 10, σ salta $2,53\times$ ($367,0 \rightarrow 929,5$) donde $\sqrt{k}$ predice sólo $1,41\times$ —la σ de $k = 5$ está estimada con *cinco* números y `ddof=0`, un estimador ruidoso y sesgado hacia abajo—, y ese exceso es lo que empuja el ES hacia arriba. Pasado el pico la relación se invierte: σ sigue creciendo, pero en promedio más lento que $\sqrt{k}$ (de $k = 500$ a LOO salta $1,09\times$ donde $\sqrt{k}$ predice $1,46\times$), porque con folds de 2 o 1 punto σ deja de medir variabilidad entre remuestreos y empieza a saturar contra la dispersión de los residuos individuales —la banda gris de la figura 8.

Las razones son dato medido; que las causas sean esas dos es la lectura más razonable del patrón, no una descomposición formal de la varianza. Lo que sí queda establecido es que el pico, 293,9 en $k = 10$, es $1,79$ veces el 164,1 que la regla de 1 ES usó en la selección del punto 5.

Consecuencia. No se cambia el esquema: el modelo de producción no se mueve (lo mostraron las dos corridas anteriores para $k = 5, 10, 20$ —la tabla de más arriba, con ocho características, y la corrida de nueve preservada en `sensibilidad_k.json`—, y no hay motivo para esperar algo distinto con las once vigentes), el nivel del error no depende de k una vez corregida la forma de promediar, y el test —evaluado **tres** veces sobre la misma partición, según D-26 y D-29— no se vuelve a tocar en este barrido. Lo que cambia es lo que este informe *declara*: el error estándar de la selección podría llegar a ser $1,79$ veces el 164,1 usado en el punto 5, no una meseta plana entre 200 y 250. Eso no debilita la elección del modelo simple —la refuerza: con un ES más ancho hay más configuraciones estadísticamente indistinguibles del mejor, no menos—.

5.6. Dónde vive el error que queda

D-23, D-27 y D-28 bajaron el RMSE de test de 4.739,33 a 4.288,52 dólares. La pregunta que sigue es si se puede bajar más, y con qué. D-30 contesta con un diagnóstico *out-of-fold* sobre train: para cada una de las 1070 filas, la predicción sale de un modelo que **no la vio** durante el ajuste —el mismo esquema de 5 folds del punto 4, pero guardando el residuo de cada fila en vez de sólo el RMSE agregado— en `src/diagnostico_residuos.py` (`resultados/diagnostico_residuos.csv`). No toca `X_test`: es un diagnóstico sobre train, no una evaluación más del modelo.

Tabla 8: Concentración del error cuadrático (SSE) sobre las filas de train, ordenadas de mayor a menor residuo.

Fracción de filas	Filas	% del SSE total
1 %	10	23,53 %
5 %	53	75,38 %
10 %	107	91,54 %

El error no está repartido. Diez personas —el 1 % del train— explican casi una cuarta parte del error cuadrático total. El 5 % explica tres cuartas partes. El modelo no está mal en todos lados por igual: está muy bien en la enorme mayoría de las filas y muy mal en un núcleo chico.

Tabla 9: Reparto del error cuadrático por población. El error se concentra en los **no fumadores**, no en los fumadores obesos que motivaron `fumador_obeso` (D-23).

Población	n	RMSE	% del SSE total
No fumadores	850	4615	86,3 %
Fumadores, $\text{bmi} \leq 30$	105	3407	5,8 %
Fumadores, $\text{bmi} > 30$	115	3804	7,9 %

Por población. Es un resultado que a primera vista sorprende: adentro de “no fumadores” hay, otra vez, una subpoblación de facto que ni `fumador_obeso` ni `bmi_si_fuma` distinguen, porque las dos características derivadas están construidas alrededor de `smoker=yes`.

El núcleo: 28 personas que ninguna columna distingue. Filtrando a los no fumadores con `charges > 25,000` —28 filas, 2,6 % del train— ese grupo aporta el **41,9 % del error cuadrático total**, y el modelo los **subestima en promedio 17.378 dólares**. Es, con amplio margen, el bloque más grande de error de todo el dataset.

Y no se los puede identificar con las columnas disponibles:

Tabla 10: Perfil de las 28 personas del núcleo contra el resto de los no fumadores. La única diferencia que se nota es la edad.

Variable	Estas 28 personas	Resto de los no fumadores
age (media)	50,79	39,11
bmi (media)	31,23	30,69
children (media)	1,39	1,10
sex	54 % F / 46 % M	51 % F / 49 % M
region	pareja a la del resto	pareja a la del resto

`Bmi`, `children`, sexo y región son prácticamente el mismo perfil que el resto de los no fumadores; sólo la edad se separa (50,8 contra 39,1), y no alcanza para aislar al grupo. Ninguna combinación de las columnas originales —ni siquiera sumando las tres características derivadas del pipeline vigente— lo separa del resto antes de ver `charges`.

Conclusión: error irreducible con este dataset. Ese ~ 42 % del error cuadrático **no es falta de capacidad del modelo**: falta la variable que explica el gasto —una patología, una cirugía, una condición preexistente— y esa variable no está en el CSV. Ninguna familia de modelos, por más flexible que sea, puede recuperar una señal que no está en las columnas de entrada; agregarle grados de libertad ahí sólo memoriza ruido, que es exactamente el sobreajuste que documenta el punto 4 en los grados 3 y 4.

Esto se verifica contra el propio historial de este trabajo: el diagnóstico se corrió **después** de D-27 y D-28, o sea sobre el pipeline ya mejorado, y el núcleo sigue concentrando el 41,9 % del error. Las dos características nuevas bajaron el RMSE de test 450,81 dólares desde el pipeline de ocho, pero no tocaron este núcleo: es la evidencia de que ese ~ 42 % es un piso, no una debilidad de esta familia de modelos en particular. **Para bajar ese tramo del error hace falta otra variable, no otro modelo.**

6. Limitaciones

- **Colinealidad en grados altos.** En grado 4, el 68,0 % de las 1364 columnas son redundantes (rango efectivo 436). Hay tres causas. Primera: una dummy binaria elevada a una

potencia sigue teniendo sólo dos valores posibles, así que es una función afín exacta de la dummy original —por ejemplo $\text{smoker}=\text{yes}^2 = 1,456866 \cdot \text{smoker}=\text{yes} + 1,0$, con un residuo de $1,5 \times 10^{-14}$, matemáticamente exacto salvo error de punto flotante—. Segunda: el producto de dos dummies del mismo one-hot cae dentro del espacio generado por las dummies individuales más la constante, porque 3 dummies y una constante ya generan todas las funciones posibles sobre las 4 regiones. Tercera, y nueva desde D-27/D-28: la expansión polinómica **duplica exactamente** a las dos características derivadas a partir de grado 2 — age^2 coincide con `edad_al_cuadrado`, y $\text{bmi} \cdot \text{smoker}=\text{yes}$ con `bmi_si_fuma`—, y es la causa de que la redundancia suba del 59,7 % (sin las dos derivadas) al 68,0 % actual, y de que cuatro configuraciones no converjan en vez de dos. En grado 1, el de producción, no hay duplicación: las once columnas son de rango completo.

Conviene aclarar que ese producto **no es idénticamente cero**: lo sería en la codificación cruda 0/1, pero como el pipeline estandariza antes de expandir, cada dummy toma valores distintos de 0 y 1 y el producto también. Sigue siendo redundante, por la segunda razón, no por ser nulo. La consecuencia práctica es que **dentro de un grupo colineal el reparto de coeficientes es arbitrario**: no se pueden interpretar de a uno cuando el grado es alto.

- **Una sola partición train/test, con una sola semilla.** El RMSE de test reportado tiene varianza asociada a qué filas cayeron del lado de test, que este trabajo no midió. Repetir el split con otra semilla daría un número distinto, presumiblemente cercano pero no idéntico.
- **El test se evaluó tres veces** (D-26, D-29). La primera con el modelo del pipeline anterior a D-23, la segunda con el modelo corregido tras el análisis exploratorio de la Clase 3 (`fumador_obeso`), la tercera con `edad_al_cuadrado` y `bmi_si_fuma` (D-27, D-28). Las tres elecciones se hicieron íntegramente con validación cruzada sobre `train` —ningún diagnóstico de `src/evidencia_features.py` ni de `src/diagnostico_residuos.py` construye `X_test`—, y este informe publica *los tres* números de test, no sólo el favorable: es la única forma de que el lector verifique que no se eligió mirando el resultado. El costo es real, no sólo nominal: reutilizar la misma partición se aparta del protocolo ideal, y cada evaluación extra erosiona un poco su independencia. Se acepta la desviación porque comparar las tres etapas sobre las mismas filas vale más que pedir una partición nueva cada vez —no porque el costo sea nulo.
- **El umbral de `fumador_obeso` no se validó como hiperparámetro.** Se tomó el de la OMS, que es externo al dataset. El barrido de umbrales de D-23 lo confirma *a posteriori*, pero si el corte se hubiera elegido por ese barrido sería un hiperparámetro ajustado contra validación y el RMSE de validación quedaría sesgado a la baja. No es el caso, y la distinción importa.
- **El dataset es simulado.** Proviene de estadísticas demográficas —el origen es el dataset del libro de Lantz— y no del registro de una aseguradora real, así que las relaciones que el modelo aprendió reflejan cómo se construyó la simulación.
- **El RMSE penaliza el error al cuadrado**, con lo cual la métrica está dominada por los casos caros. Un modelo puede tener un RMSE relativamente bueno y aun así errar de forma proporcionalmente grande en los casos baratos.

7. Guion de la presentación (10 minutos)

Tabla 11: Reparto del tiempo. La introducción teórica y el punto 5 son lo que más se evalúa.

Min.	Qué se dice	Figura
0-1	Dataset (<code>insurance.csv</code> , 1338 filas) y la pregunta del TP: predecir <code>charges</code> y elegir un modelo defendible, no sólo el de menor error.	—
1-3	Introducción teórica: por qué <code>train</code> no alcanza, qué rol cumple cada conjunto, por qué el <code>test</code> se toca una sola vez, y qué gana la validación cruzada frente a un único <code>split</code> .	—
3-4	Punto 1: por qué se conservan los 139 outliers (97,8 % fumadores) y por qué IQR y no <code>z-score</code> .	04-outliers
4-5	Puntos 2 y 3: el pipeline y por qué la regresión polinómica sigue siendo lineal en los parámetros.	—
5-7	Punto 4: las curvas por grado, dónde aparece el sobreajuste (la brecha de 61,8 a 84.537,9, el desvío de ± 367 a ± 47.000) y cómo Lasso lo corrige.	01-curvas, 02-camino
7-9	Punto 5, el núcleo: por qué el lineal grado 1 gana la CV siendo además el más simple del espacio, por qué 7 de las 15 son indistinguibles y confirman la misma elección, y el RMSE prometido, con el sesgo del mínimo.	una-es
9-10	Limitaciones y cierre.	—

A. Reproducibilidad

El repositorio corre con Python 3.10 o superior y solamente `numpy`, `pandas` y `matplotlib`. No usa `scikit-learn` ni `pytest`.

Comando	Qué hace
<code>python -m src.datos</code>	Punto 1: análisis exploratorio
<code>python -m src.experimentos</code>	Puntos 2 a 5 (unos 27 minutos)
<code>python -m src.evidencia_features</code>	La evidencia numérica de D-23, D-24, D-25, D-27 y D-28
<code>python -m src.diagnostico_residuos</code>	El diagnóstico de residuos y el error irreducible de D-30
<code>python -m src.graficos</code>	Genera las figuras de este informe
<code>python -m src.tablas</code>	Regenera las tablas del punto 4 desde los CSV
<code>python -m src.sensibilidad_k</code>	Barrido de k de la sección 5.5 (parte B, minutos; parte A completa)
<code>python -m tests.test_validacion</code>	Suite del módulo de partición y métricas
<code>python -m tests.test_preproceso</code>	Suite de codificación, escalado y expansión
<code>python -m tests.test_modelos</code>	Suite de los modelos
<code>python -m tests.test_paleta</code>	La paleta de las figuras, bajo simulación de daltonismo

Los resultados están versionados en `resultados/` (`cv_lineal.csv`, `cv_lasso.csv`, `modelo_elegido.json`, `evaluacion_test.json`, `evidencia_features.csv`, `diagnostico_residuos.csv`, `sensibilidad_k.json`, `sensibilidad_k.csv`, `sensibilidad_k_previo_d23.json`, `sensibilidad_k_previo_d27.json` y `evaluacion_test_previo_d27.json`), junto con la salida completa de la corrida en `informe/salida-seleccion.txt`, de modo que no hace falta correr nada para verificar los números de este informe. Las decisiones metodológicas están numeradas y justificadas una por una en `DECISIONES.md`.

Procedencia del dataset. El archivo se descargó del enlace que da el enunciado (kaggle.com/datasets/mir) y se verificó que la copia usada es byte a byte idéntica al original publicado:

SHA256 = 388eff679557d08ac19f463d025de5e0b4adc482537c8456d19934d78621fd47