

Regresión e introducción a la evaluación de modelos

Trabajo Práctico 1

72.75 — Aprendizaje Automático

Instituto Tecnológico de Buenos Aires

26 de agosto de 2026

Dataset: Insurance Charges — 1338 registros, 7 variables

Qué hay que predecir

Predecir el **costo médico anual** de una persona a partir de:

Qué hay que predecir

Predecir el **costo médico anual** de una persona a partir de:

- age, bmi, children — numéricas

Qué hay que predecir

Predecir el **costo médico anual** de una persona a partir de:

- age, bmi, children — numéricas
- sex, smoker — binarias

Qué hay que predecir

Predecir el **costo médico anual** de una persona a partir de:

- age, bmi, children — numéricas
- sex, smoker — binarias
- region — nominal, 4 categorías

Qué hay que predecir

Predecir el **costo médico anual** de una persona a partir de:

- age, bmi, children — numéricas
- sex, smoker — binarias
- region — nominal, 4 categorías

La pregunta real del TP

No es cuál modelo ajusta mejor.

Es **cuál modelo elegiría** y **qué error prometería**.

Qué hay que predecir


Predecir el **costo médico anual** de una persona a partir de:

- age, bmi, children — numéricas
- sex, smoker — binarias
- region — nominal, 4 categorías

La pregunta real del TP

No es cuál modelo ajusta mejor.

Es **cuál modelo elegiría** y **qué error prometería**.



Cómo se evalúa: los tres conjuntos y la validación cruzada

train — 1070 filas

test — 267

se toca **una vez**, al final

Cómo se evalúa: los tres conjuntos y la validación cruzada

train — 1070 filas

test — 267

se toca **una vez**, al final

fold 1

valida

entrena

entrena

entrena

entrena

Cómo se evalúa: los tres conjuntos y la validación cruzada

train — 1070 filas

test — 267

se toca **una vez**, al final

fold 1

valida

entrena

entrena

entrena

entrena

fold 2

entrena

valida

entrena

entrena

entrena

Cómo se evalúa: los tres conjuntos y la validación cruzada

train — 1070 filas

test — 267

se toca **una vez**, al final



Cómo se evalúa: los tres conjuntos y la validación cruzada

train — 1070 filas

test — 267

se toca **una vez**, al final

fold 1	valida	entrena	entrena	entrena	entrena
fold 2	entrena	valida	entrena	entrena	entrena
fold 3	entrena	entrena	valida	entrena	entrena
fold 4	entrena	entrena	entrena	valida	entrena

Cómo se evalúa: los tres conjuntos y la validación cruzada


train — 1070 filas

test — 267


se toca **una vez**, al final

fold 1	valida	entrena	entrena	entrena	entrena
fold 2	entrena	valida	entrena	entrena	entrena
fold 3	entrena	entrena	valida	entrena	entrena
fold 4	entrena	entrena	entrena	valida	entrena
fold 5	entrena	entrena	entrena	entrena	valida

Cómo se evalúa: los tres conjuntos y la validación cruzada




Cómo se evalúa: los tres conjuntos y la validación cruzada



Por qué no alcanza el error de train

El modelo ajustó sus parámetros para minimizarlo. Un valor bajo puede ser que aprendió o que memorizó: no distingue.

Cómo se evalúa: los tres conjuntos y la validación cruzada





Por qué no alcanza el error de train

El modelo ajustó sus parámetros para minimizarlo. Un valor bajo puede ser que aprendió o que memorizó: no distingue.



Por qué el test se toca una sola vez

En cuanto se lo usa para decidir algo pasa a ser un segundo conjunto de validación, y su número deja de estimar el error real.

Los outliers: ¿error de carga o subpoblación real?



Los outliers: ¿error de carga o subpoblación real?



139 outliers por IQR (10,4 %) — y el **97,8 %** son fumadores, contra 11,5 % en el resto.

El criterio importa: IQR contra z-score

Variable	IQR detecta	Z-score detecta
charges	139	7
children	0	18

El criterio importa: IQR contra z-score

Variable	IQR detecta	Z-score detecta
charges	139	7
children	0	18

- En charges el z-score detecta 20 veces menos: la asimetría es 1,516, y **los propios extremos inflan el desvío** que el z-score usa de referencia. El criterio se sabotea a sí mismo.

El criterio importa: IQR contra z-score

Variable	IQR detecta	Z-score detecta
charges	139	7
children	0	18

- En charges el z-score detecta 20 veces menos: la asimetría es 1,516, y **los propios extremos inflan el desvío** que el z-score usa de referencia. El criterio se sabotea a sí mismo.
- En children pasa lo inverso: es un entero de 0 a 5, y “tres desvíos” no significa nada en una variable así.


El criterio importa: IQR contra z-score

Variable	IQR detecta	Z-score detecta
charges	139	7
children	0	18


- En charges el z-score detecta 20 veces menos: la asimetría es 1,516, y **los propios extremos inflan el desvío** que el z-score usa de referencia. El criterio se sabotea a sí mismo.
- En children pasa lo inverso: es un entero de 0 a 5, y “tres desvíos” no significa nada en una variable así.

Se usa **IQR**, que se apoya en cuartiles y es robusto a la asimetría.

Dentro de cada fold, en este orden




Dentro de cada fold, en este orden




- Los dos estandarizadores se ajustan **sólo con el sub-train del fold**. Ajustarlos antes de partir sería **fuga de datos**: la media de validación se filtraría al entrenamiento.

Dentro de cada fold, en este orden




- Los dos estandarizadores se ajustan **sólo con el sub-train del fold**. Ajustarlos antes de partir sería **fuga de datos**: la media de validación se filtraría al entrenamiento.
- El primer escalado evita que $\text{age}^3 = 262\,144$ conviva con $\text{children}^3 = 125$.

Dentro de cada fold, en este orden



- Los dos estandarizadores se ajustan **sólo con el sub-train del fold**. Ajustarlos antes de partir sería **fuga de datos**: la media de validación se filtraría al entrenamiento.
- El primer escalado evita que $\text{age}^3 = 262\,144$ conviva con $\text{children}^3 = 125$.
- El segundo hace que la penalización L_1 sea comparable entre features.


Dentro de cada fold, en este orden



- Los dos estandarizadores se ajustan **sólo con el sub-train del fold**. Ajustarlos antes de partir sería **fuga de datos**: la media de validación se filtraría al entrenamiento.
- El primer escalado evita que $\text{age}^3 = 262\,144$ conviva con $\text{children}^3 = 125$.
- El segundo hace que la penalización L_1 sea comparable entre features.


La regresión polinómica sigue siendo **lineal en los parámetros**: se transforman las columnas, no el modelo.

Qué pasa al subir el grado del polinomio




Si mirásemos sólo esto, la conclusión sería “más grado siempre es mejor”.

Qué pasa al subir el grado del polinomio




Mejora hasta grado 2 y después **empeora**. El de grado 4 es peor que el lineal simple.

Qué pasa al subir el grado del polinomio



La banda es ± 1 desvío entre folds: ± 244 en grado 2 contra ± 1031 en grado 4.

Qué pasa al subir el grado del polinomio



El grado 4 no es sólo peor: es **inestable**, cambia según cómo caiga la partición.

Los dos indicadores de sobreajuste

1. La brecha train-validación

grado 1 88

grado 4 **2508**

Un modelo que generaliza tiene los dos errores parecidos. Una brecha que se ensancha es la firma directa del sobreajuste.

Los dos indicadores de sobreajuste

1. La brecha train–validación

grado 1	88
grado 4	2508

Un modelo que generaliza tiene los dos errores parecidos. Una brecha que se ensancha es la firma directa del sobreajuste.

2. El desvío entre folds

grado 1	± 89
grado 4	$\pm$ 1031

Más de diez veces mayor. No dice “peor en promedio”: dice **poco confiable**.

Los dos indicadores de sobreajuste

1. La brecha train–validación

grado 1	88
grado 4	2508

Un modelo que generaliza tiene los dos errores parecidos. Una brecha que se ensancha es la firma directa del sobreajuste.

2. El desvío entre folds



grado 1	± 89
grado 4	$\pm \mathbf{1031}$

Más de diez veces mayor. No dice “peor en promedio”: dice **poco confiable**.

El error de train de grado 4 es el **mejor de toda la tabla** (4058).

Por eso el error de train no sirve para elegir.

Lasso: regularizar recupera la estabilidad



Al aflojar λ entran más features y el error primero baja y después sube.
En grado 4, la penalización L_1 deja vivos **26 de 494** coeficientes.


1. ¿Qué modelo obtuvo menor error?

Lasso grado 4

$\lambda = 286,37$ — RMSE de validación = $4920,0 \pm 224,3$


Y sin embargo, **no es el que llevaría a producción.**

2. ¿Cuál implementaría en una aplicación real?




Están separadas por decenas de dólares. . .

2. ¿Cuál implementaría en una aplicación real?



... pero el desvío entre folds es de **224**. El error estándar es $224,3/\sqrt{5} = 100,3$.

2. ¿Cuál implementaría en una aplicación real?



8 de 18 configuraciones son estadísticamente indistinguibles.
Cuál sale primera lo decide el azar de la partición, no el modelo.

Entre indistinguibles, el más simple

	Features	Coefs. vivos	RMSE test
Ganador de la CV (grado 4)	494	20	4.647,34
Producción (grado 2)	44	10	4.739,33

Entre indistinguibles, el más simple

	Features	Coefs. vivos	RMSE test
Ganador de la CV (grado 4)	494	20	4.647,34
Producción (grado 2)	44	10	4.739,33

La simplicidad cuesta **+92 dólares de RMSE** — un 2 % —
y compra un espacio de features **11 veces más chico**.

Entre indistinguibles, el más simple

	Features	Coefs. vivos	RMSE test
Ganador de la CV (grado 4)	494	20	4.647,34
Producción (grado 2)	44	10	4.739,33
Lineal simple (grado 1)	8	8	6.057,69
Predecir siempre la media	—	0	11.963,43

La simplicidad cuesta **+92 dólares de RMSE** — un 2 % —
y compra un espacio de features **11 veces más chico**.

3. ¿Qué RMSE esperar en datos nuevos?

4.739,33

RMSE de **test** del modelo de producción, en dólares

3. ¿Qué RMSE esperar en datos nuevos?

4.739,33

RMSE de **test** del modelo de producción, en dólares

No los **4955** de validación.

Por qué el número de validación está sesgado a la baja

Esa configuración se eligió por ser el **mínimo** de 19 estimaciones ruidosas. El mínimo de un conjunto de estimaciones ruidosas está sesgado hacia abajo *aunque cada una sea insesgada*: es probable que el ganador lo sea en parte por una racha favorable de ruido.

3. ¿Qué RMSE esperar en datos nuevos?

4.739,33

RMSE de **test** del modelo de producción, en dólares


No los **4955** de validación.

Por qué el número de validación está sesgado a la baja

Esa configuración se eligió por ser el **mínimo** de 19 estimaciones ruidosas. El mínimo de un conjunto de estimaciones ruidosas está sesgado hacia abajo *aunque cada una sea insesgada*: es probable que el ganador lo sea en parte por una racha favorable de ruido.


Dos advertencias: el test tiene 267 filas (el número tiene su propia incertidumbre), y el RMSE promedia sobre una población heterogénea — el error se concentra en los fumadores.

Por qué el polinomio mejora: hay dos poblaciones




Correlación de Pearson: **0,198**. Parece una variable poco informativa.

Por qué el polinomio mejora: hay dos poblaciones



Eran **dos poblaciones superpuestas**.

Por qué el polinomio mejora: hay dos poblaciones



Un factor de **17,7** entre las pendientes. Eso es un término $\text{bmi} \times \text{smoker}$, que un modelo aditivo no puede representar.

El Lasso lo encontró solo

Feature	Coeficiente
smoker=yes	9301,54
age	3463,37
bmi*smoker=yes	3317,35

El Lasso lo encontró solo

Feature	Coeficiente
smoker=yes	9301,54
age	3463,37
bmi*smoker=yes	3317,35
bmi	1595,81

El término de interacción quedó **por encima de bmi sola**.

Sin que nadie se lo indicara, la penalización L_1 recuperó el mismo fenómeno que el análisis exploratorio había encontrado a mano.

El Lasso lo encontró solo

Feature	Coeficiente
smoker=yes	9301,54
age	3463,37
bmi*smoker=yes	3317,35
bmi	1595,81

El término de interacción quedó **por encima de bmi sola**.

Sin que nadie se lo indicara, la penalización L_1 recuperó el mismo fenómeno que el análisis exploratorio había encontrado a mano.

De 44 features, sobreviven 10. L_1 las apaga en **cero exacto**; L_2 las habría encogido sin anular ninguna.

Limitaciones

- **Colinealidad en grados altos.** En grado 4, el **56 %** de las 494 columnas son redundantes: una dummy al cuadrado es función afín exacta de sí misma. Los coeficientes de un grupo colineal **no se interpretan de a uno**.

Limitaciones

- **Colinealidad en grados altos.** En grado 4, el **56 %** de las 494 columnas son redundantes: una dummy al cuadrado es función afín exacta de sí misma. Los coeficientes de un grupo colineal **no se interpretan de a uno**.
- **Una sola semilla.** El RMSE de test tiene varianza asociada a qué filas cayeron en test, que no medimos.

Limitaciones

- **Colinealidad en grados altos.** En grado 4, el **56 %** de las 494 columnas son redundantes: una dummy al cuadrado es función afín exacta de sí misma. Los coeficientes de un grupo colineal **no se interpretan de a uno**.
- **Una sola semilla.** El RMSE de test tiene varianza asociada a qué filas cayeron en test, que no medimos.
- **El dataset es simulado**, no el registro de una aseguradora real.

Limitaciones

- **Colinealidad en grados altos.** En grado 4, el **56 %** de las 494 columnas son redundantes: una dummy al cuadrado es función afín exacta de sí misma. Los coeficientes de un grupo colineal **no se interpretan de a uno**.
- **Una sola semilla.** El RMSE de test tiene varianza asociada a qué filas cayeron en test, que no medimos.
- **El dataset es simulado**, no el registro de una aseguradora real.
- **El RMSE penaliza al cuadrado**, así que está dominado por los casos caros.

El modelo que llevaría a producción es un
Lasso de grado 2 con 10 features vivas

y esperaría un error típico de
4.739,33

No es el de menor error de validación.
Es el más simple entre los que son **estadísticamente indistinguibles** de él.

El modelo que llevaría a producción es un
Lasso de grado 2 con 10 features vivas

y esperaría un error típico de
4.739,33

No es el de menor error de validación.
Es el más simple entre los que son **estadísticamente indistinguibles** de él.

Todo implementado desde cero sobre `numpy`: `split`, `k-fold`, `one-hot`, estandarizado, ecuación normal, expansión polinómica y Lasso.

Slides de respaldo

para las preguntas

Respaldo: el diagnóstico de rango

Grado	Columnas	Rango efectivo	Redundantes
1	8	8	0
2	44	36	8 (18 %)
3	164	100	64 (39 %)
4	494	216	278 (56 %)

- Una dummy al cuadrado sigue teniendo dos valores:
 $\text{smoker}^2 = 1,456866 \cdot \text{smoker} + 1,0$, residuo $1,5 \times 10^{-14}$.
- El producto de dos dummies del mismo one-hot ya vive en el espacio generado por las dummies y la constante.
- **No** es que ese producto sea cero: lo sería en la codificación cruda 0/1, pero estandarizamos *antes* de expandir.


Respaldo: por qué 1stsq y no invertir $X^T X$

El número de condición completo de la matriz de diseño estandarizada:

Grado	1	2	3	4
κ	2,2	$1,8 \times 10^{16}$	$8,7 \times 10^{16}$	$3,1 \times 10^{18}$

- De grado 2 en adelante supera la precisión de float64 ($\approx 10^{16}$): la matriz es **numéricamente singular**.
- `np.linalg.inv` devolvería basura. 1stsq usa SVD y da la solución de norma mínima.
- Restringido al subespacio de rango completo el condicionamiento es benigno (4,0 / 18,4 / 129,4): las **predicciones** son estables. Lo que no lo es es el reparto de coeficientes.

Respaldo: el modelo sobre el test



Acierta con precisión en la mayoría barata y se dispersa en los casos caros, que son casi todos fumadores.

Es la asimetría del error que la tercera respuesta advierte

Respaldo: cómo verificamos los números

Chequeo	Resultado
RMSE de CV recalculado sin usar el módulo	coincide a 0,1
RMSE de test (producción y referencias)	coincide a 0,01
Lasso contra <code>scipy.optimize</code>	coincide a 8 decimales
Usos de <code>X_test</code> antes del punto 5	4 usos, 0 sospechosos
Alineación de los 494 nombres de grado 4	verificada
Suites de tests	3/3 en verde

La alineación de nombres se verificó asignando un **primo distinto a cada columna**: el valor de cada monomio es entonces un producto de primos que factoriza unívocamente al monomio.