


Regresión e introducción a la evaluación de modelos

72.75 — Aprendizaje Automático
Instituto Tecnológico de Buenos Aires

Dataset: Insurance Charges — 1338 registros, 7 variables
26 de agosto de 2026


Qué hay que predecir

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)




Qué hay que predecir

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)




Qué hay que predecir

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)




Qué hay que predecir

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)



Qué hay que predecir

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)



La pregunta real no es cuál ajusta mejor:
es **cuál modelo elegiría** y **qué error prometería**.

Los tres conjuntos, y por qué hacen falta los tres

El problema · [Train/val/test](#) · Limpieza · Pipeline · Resultados · Las tres respuestas · El hallazgo · Cierre

- **train** — ajusta los **parámetros** del modelo (los coeficientes).

Los tres conjuntos, y por qué hacen falta los tres

El problema · [Train/val/test](#) · Limpieza · Pipeline · Resultados · Las tres respuestas · El hallazgo · Cierre

- **train** — ajusta los **parámetros** del modelo (los coeficientes).
- **validación** — no ajusta nada: **elige** entre configuraciones (qué grado, qué λ). Acá es la CV de 5 folds, dentro de train.

Los tres conjuntos, y por qué hacen falta los tres

El problema · [Train/val/test](#) · Limpieza · Pipeline · Resultados · Las tres respuestas · El hallazgo · Cierre

- **train** — ajusta los **parámetros** del modelo (los coeficientes).
- **validación** — no ajusta nada: **elige** entre configuraciones (qué grado, qué λ). Acá es la CV de 5 folds, dentro de train.
- **test** — **no participa de ninguna decisión**. Se toca una vez, al final.

Los tres conjuntos, y por qué hacen falta los tres

El problema · [Train/val/test](#) · Limpieza · Pipeline · Resultados · Las tres respuestas · El hallazgo · Cierre

- **train** — ajusta los **parámetros** del modelo (los coeficientes).
- **validación** — no ajusta nada: **elige** entre configuraciones (qué grado, qué λ). Acá es la CV de 5 folds, dentro de train.
- **test** — **no participa de ninguna decisión**. Se toca una vez, al final.

¿Por qué no alcanza con dos? El error medido sobre datos que participaron de una decisión queda **sesgado a la baja**.

El modelo aprende del train — por eso el error de train miente. Pero **nosotros** aprendemos del set con el que elegimos — por eso ese error *también* miente.

Hace falta un tercero que no haya visto ninguna de las dos cosas.

Cómo se parten los datos, y por qué así

El problema · [Train/val/test](#) · Limpieza · Pipeline · Resultados · Las tres respuestas · El hallazgo · Cierre

1337 filas · 1338 del archivo, menos 1 duplicado exacto

train

1070 filas · 80 %

test

267 filas · 20 %

adentro: 5 folds de ≈ 214 filas

Cómo se parten los datos, y por qué así

El problema · [Train/val/test](#) · Limpieza · Pipeline · Resultados · Las tres respuestas · El hallazgo · Cierre

1337 filas · 1338 del archivo, menos 1 duplicado exacto

train

1070 filas · 80 %

test

267 filas · 20 %

adentro: 5 folds de ≈ 214 filas

- **1337, no 1338** — el duplicado exacto se elimina **antes** de partir.

Cómo se parten los datos, y por qué así

El problema · [Train/val/test](#) · Limpieza · Pipeline · Resultados · Las tres respuestas · El hallazgo · Cierre

1337 filas · 1338 del archivo, menos 1 duplicado exacto

train

1070 filas · 80 %

test

267 filas · 20 %

adentro: 5 folds de ≈ 214 filas

- **1337, no 1338** — el duplicado exacto se elimina **antes** de partir.
- **80/20 con semilla fija** — barajado simple, **sin estratificar**.

Cómo se parten los datos, y por qué así

El problema · [Train/val/test](#) · Limpieza · Pipeline · Resultados · Las tres respuestas · El hallazgo · Cierre

1337 filas · 1338 del archivo, menos 1 duplicado exacto

train

1070 filas · 80 %

test

267 filas · 20 %



adentro: 5 folds de ≈ 214 filas

- **1337, no 1338** — el duplicado exacto se elimina **antes** de partir.
- **80/20 con semilla fija** — barajado simple, **sin estratificar**.
- **El split va antes del EDA** — el análisis exploratorio también decide.

Los outliers: ¿error de carga o subpoblación real?

El problema · Train/val/test · [Limpieza](#) · Pipeline · Resultados · Las tres respuestas · El hallazgo · Cierre



El criterio: la caja es el 50 % del medio, y el corte está 1,5 cajas más a la derecha
(115 outliers, 10.7 % de la muestra)



Los outliers: ¿error de carga o subpoblación real?

El problema · Train/val/test · [Limpieza](#) · Pipeline · Resultados · Las tres respuestas · El hallazgo · Cierre

El criterio: la caja es el 50 % del medio, y el corte está 1,5 cajas más a la derecha
(115 outliers, 10.7 % de la muestra)



97,4 % fumadores contra 11,3 % — **no es azar: se conservan.**

El criterio importa: IQR contra z-score

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

VARIABLE	IQR DETECTA	Z-SCORE DETECTA
charges	115	5
children	0	16

El criterio importa: IQR contra z-score

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

VARIABLE	IQR DETECTA	Z-SCORE DETECTA
charges	115	5
children	0	16

- charges: **los extremos inflan el desvío** — el z-score se sabotea solo.

El criterio importa: IQR contra z-score

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

VARIABLE	IQR DETECTA	Z-SCORE DETECTA
charges	115	5
children	0	16

- charges: **los extremos inflan el desvío** — el z-score se sabotea solo.
- children: entera de 0 a 5 — “tres desvíos” no significa nada.

El criterio importa: IQR contra z-score

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

VARIABLE	IQR DETECTA	Z-SCORE DETECTA
charges	115	5
children	0	16

- charges: **los extremos inflan el desvío** — el z-score se sabotea solo.
- children: entera de 0 a 5 — “tres desvíos” no significa nada.

Se usa **IQR**: cuartiles, robusto a la asimetría.

Dentro de cada fold, en este orden

El problema · Train/val/test · Limpieza · **Pipeline** · Resultados · Las tres respuestas · El hallazgo · Cierre

codificar
one-hot


Dentro de cada fold, en este orden

El problema · Train/val/test · Limpieza · [Pipeline](#) · Resultados · Las tres respuestas · El hallazgo · Cierre



Dentro de cada fold, en este orden

El problema · Train/val/test · Limpieza · [Pipeline](#) · Resultados · Las tres respuestas · El hallazgo · Cierre




Dentro de cada fold, en este orden

El problema · Train/val/test · Limpieza · **Pipeline** · Resultados · Las tres respuestas · El hallazgo · Cierre




Dentro de cada fold, en este orden

El problema · Train/val/test · Limpieza · **Pipeline** · Resultados · Las tres respuestas · El hallazgo · Cierre



Dentro de cada fold, en este orden


El problema · Train/val/test · Limpieza · **Pipeline** · Resultados · Las tres respuestas · El hallazgo · Cierre



- Estandarizadores ajustados **sólo con el sub-train** — sin **fuga de datos**.

Dentro de cada fold, en este orden


El problema · Train/val/test · Limpieza · **Pipeline** · Resultados · Las tres respuestas · El hallazgo · Cierre



- Estandarizadores ajustados **sólo con el sub-train** — sin **fuga de datos**.
- Primer escalado: $\text{age}^3 = 262\,144$ contra $\text{children}^3 = 125$.

Dentro de cada fold, en este orden


El problema · Train/val/test · Limpieza · **Pipeline** · Resultados · Las tres respuestas · El hallazgo · Cierre



- Estandarizadores ajustados **sólo con el sub-train** — sin **fuga de datos**.
- Primer escalado: $\text{age}^3 = 262\,144$ contra $\text{children}^3 = 125$.
- Segundo: penalización L_1 **comparable entre features**.

Dentro de cada fold, en este orden

El problema · Train/val/test · Limpieza · Pipeline · Resultados · Las tres respuestas · El hallazgo · Cierre




- Estandarizadores ajustados **sólo con el sub-train** — sin **fuga de datos**.
- Primer escalado: $\text{age}^3 = 262\,144$ contra $\text{children}^3 = 125$.
- Segundo: penalización L_1 **comparable entre features**.

La polinómica sigue siendo **lineal en los parámetros**: se transforman las columnas, no el modelo.

Qué pasa al subir el grado del polinomio

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

El error de entrenamiento baja siempre




Si mirásemos sólo esto, la conclusión sería “más grado siempre es mejor”.

Qué pasa al subir el grado del polinomio

El problema · Train/val/test · Limpieza · Pipeline · **Resultados** · Las tres respuestas · El hallazgo · Cierre


...pero el de validación deja de acompañarlo



No mejora en **ningún** grado: empata en 2 y de ahí empeora. El grado 4 se sale del gráfico.

Qué pasa al subir el grado del polinomio

El problema · Train/val/test · Limpieza · Pipeline · [Resultados](#) · Las tres respuestas · El hallazgo · Cierre




La banda es ± 1 desvío entre folds: $\pm 367,0$ en grado 1 contra $\pm 47.000,1$ en grado 4.

Qué pasa al subir el grado del polinomio

El problema · Train/val/test · Limpieza · Pipeline · [Resultados](#) · Las tres respuestas · El hallazgo · Cierre

Sin regularizar, el mínimo de validación está en grado 1: el modelo más simple



El grado 4 no es sólo peor: es **inestable**, cambia según cómo caiga la partición.

Los dos indicadores de sobreajuste

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

BRECHA TRAIN-VALIDACIÓN

61,8 → **84.537,9**
de grado 1 a grado 4

Los dos indicadores de sobreajuste

El problema · Train/val/test · Limpieza · Pipeline · **Resultados** · Las tres respuestas · El hallazgo · Cierre

BRECHA TRAIN-VALIDACIÓN

61,8 → **84.537,9**
de grado 1 a grado 4

DESVÍO ENTRE FOLDS

$\pm 367,0$ → **$\pm 47.000,1$**
de grado 1 a grado 4

Los dos indicadores de sobreajuste

El problema · Train/val/test · Limpieza · Pipeline · **Resultados** · Las tres respuestas · El hallazgo · Cierre

BRECHA TRAIN-VALIDACIÓN

61,8 → **84.537,9**
de grado 1 a grado 4

DESVÍO ENTRE FOLDS

$\pm 367,0$ → **$\pm 47.000,1$**
de grado 1 a grado 4


El train de grado 4 es el **mejor de toda la tabla** (3379,1).

Por eso el error de train no sirve para elegir.


Lasso: regularizar recupera la estabilidad

El problema · Train/val/test · Limpieza · Pipeline · **Resultados** · Las tres respuestas · El hallazgo · Cierre

El error baja y vuelve a subir



Al aflojar λ entran más features



En grado 4, la penalización L_1 deja vivos **17 de 1.364** coeficientes.

1. ¿Qué modelo obtuvo menor error?

El problema · Train/val/test · Limpieza · Pipeline · Resultados · [Las tres respuestas](#) · El hallazgo · Cierre


Lineal grado 1

RMSE de validación = $4413,4 \pm 367,0$

Y es, a la vez, **el más simple** de todo el espacio de búsqueda.

2. ¿Cuál implementaría en una aplicación real?


El problema · Train/val/test · Limpieza · Pipeline · Resultados · [Las tres respuestas](#) · El hallazgo · Cierre



Separadas por **decenas de dólares...**

2. ¿Cuál implementaría en una aplicación real?


El problema · Train/val/test · Limpieza · Pipeline · Resultados · [Las tres respuestas](#) · El hallazgo · Cierre



...con un error estándar de **164,1**.

2. ¿Cuál implementaría en una aplicación real?

El problema · Train/val/test · Limpieza · Pipeline · Resultados · [Las tres respuestas](#) · El hallazgo · Cierre



7 de 15 son estadísticamente indistinguibles: la regla de 1 ES **confirma** al lineal de grado 1, no lo decide.

El resultado sobre test

El problema · Train/val/test · Limpieza · Pipeline · Resultados · [Las tres respuestas](#) · El hallazgo · Cierre

MODELO	FEATURES	RMSE TEST	R^2 TEST
Predecir siempre la media	—	11.963,43	0,000

El resultado sobre test

El problema · Train/val/test · Limpieza · Pipeline · Resultados · [Las tres respuestas](#) · El hallazgo · Cierre

MODELO	FEATURES	RMSE TEST	R^2 TEST
Predecir siempre la media	—	11.963,43	0,000
Lineal grado 1, sin regularizar	11	4.288,52	0,871

El resultado sobre test

El problema · Train/val/test · Limpieza · Pipeline · Resultados · [Las tres respuestas](#) · El hallazgo · Cierre

MODELO	FEATURES	RMSE TEST	R^2 TEST
Predecir siempre la media	—	11.963,43	0,000
Lineal grado 1, sin regularizar	11	4.288,52	0,871

2,79 veces mejor que predecir la media · explica el **87,1 %** de la varianza de charges en datos que nunca vio.

El resultado sobre test

El problema · Train/val/test · Limpieza · Pipeline · Resultados · [Las tres respuestas](#) · El hallazgo · Cierre

MODELO	FEATURES	RMSE TEST	R^2 TEST
Predecir siempre la media	—	11.963,43	0,000
Lineal grado 1, sin regularizar	11	4.288,52	0,871

2,79 veces mejor que predecir la media · explica el **87,1 %** de la varianza de charges en datos que nunca vio.

Las 267 filas de test no participaron de ninguna decisión: ni del split, ni del EDA, ni de la elección de grado o λ .

3. ¿Qué RMSE esperar en datos nuevos?

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

4.288,52

RMSE de **test** del modelo de producción, en dólares

3. ¿Qué RMSE esperar en datos nuevos?

El problema · Train/val/test · Limpieza · Pipeline · Resultados · [Las tres respuestas](#) · El hallazgo · Cierre

4.288,52

RMSE de **test** del modelo de producción, en dólares

No los 4.413,45 de validación:


producción **es** el mínimo de validación entre las 15 configuraciones elegibles — y el mínimo de un conjunto así queda sesgado a la baja.

El histograma que cambió el modelo


El problema · Train/val/test · Limpieza · Pipeline · Resultados · Las tres respuestas · **El hallazgo** · Cierre

charges no es una distribución con cola: son tres poblaciones

Lo que se ve en la figura 7: un pico grande, y dos jorobas más a la derecha



El mismo histograma separado por población: cada joroba es un grupo



charges no tiene un centro: tiene **tres**.

El histograma que cambió el modelo


El problema · Train/val/test · Limpieza · Pipeline · Resultados · Las tres respuestas · **El hallazgo** · Cierre

charges no es una distribución con cola: son tres poblaciones

Lo que se ve en la figura 7: un pico grande, y dos jorobas más a la derecha



El mismo histograma separado por población: cada joroba es un grupo



El tercer grupo arranca en **\$32.548**, por encima del **99,1 %** de todos los demás.

Una columna nueva vale más que todo el polinomio

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

LINEAL, SIN LA COLUMNA

6.094

RMSE de validación

Una columna nueva vale más que todo el polinomio

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

LINEAL, SIN LA COLUMNA

6.094

RMSE de validación

LINEAL, CON LA COLUMNA

4.455

RMSE de validación

Una columna nueva vale más que todo el polinomio

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

LINEAL, SIN LA COLUMNA

6.094

RMSE de validación

LINEAL, CON LA COLUMNA

4.455

RMSE de validación

El mejor Lasso *sin* la columna daba 4.913, con 44 features.

fumador_obeso = (fuma) $\wedge$ (bmi > 30). El umbral es el de la OMS, no uno ajustado a los datos.

Una columna nueva vale más que todo el polinomio

El problema · Train/val/test · Limpieza · Pipeline · Resultados · Las tres respuestas · [El hallazgo](#) · Cierre

LINEAL, SIN LA COLUMNA

6.094

RMSE de validación

LINEAL, CON LA COLUMNA

4.455

RMSE de validación

El mejor Lasso *sin* la columna daba 4.913, con 44 features.

fumador_obeso = (fuma) $\wedge$ (bmi > 30). El umbral es el de la OMS, no uno ajustado a los datos.

El mismo método sumó después dos columnas más — edad_al_cuadrado y bmi_si_fuma —: y bajan el RMSE de validación de 4.455 a **4.380**.

El modelo entero, en once números

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

CARACTERÍSTICA	COEFICIENTE
bmi_si_fuma	5236,99
fumador_obeso	4891,83

El modelo entero, en once números

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

CARACTERÍSTICA	COEFICIENTE
bmi_si_fuma	5236,99
fumador_obeso	4891,83
edad_al_cuadrado	3749,13
smoker=yes	1161,22
children	815,02
bmi	111,20

Las **tres columnas derivadas** encabezan el modelo: ninguna venía en el CSV.

El modelo entero, en once números

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

CARACTERÍSTICA	COEFICIENTE
bmi_si_fuma	5236,99
fumador_obeso	4891,83
edad_al_cuadrado	3749,13
smoker=yes	1161,22
children	815,02
bmi	111,20

Las **tres columnas derivadas** encabezan el modelo: ninguna venía en el CSV.

Sobre features estandarizadas: las magnitudes son comparables entre sí.

Limitaciones

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

| Colinealidad en grados altos

En grado 4, el **68 %** de las 1364 columnas es redundante: **no se interpretan de a uno.**

Limitaciones

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

| Colinealidad en grados altos

En grado 4, el **68 %** de las 1364 columnas es redundante: **no se interpretan de a uno.**

| Una sola semilla

La varianza de qué filas caen en test **no está medida.**

Limitaciones

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

| Colinealidad en grados altos

En grado 4, el **68 %** de las 1364 columnas es redundante: **no se interpretan de a uno.**

| Una sola semilla

La varianza de qué filas caen en test **no está medida.**

| Dataset simulado

No es el registro de una aseguradora real.

Limitaciones

[El problema](#) · [Train/val/test](#) · [Limpieza](#) · [Pipeline](#) · [Resultados](#) · [Las tres respuestas](#) · [El hallazgo](#) · [Cierre](#)

| Colinealidad en grados altos

En grado 4, el **68 %** de las 1364 columnas es redundante: **no se interpretan de a uno.**

| Una sola semilla

La varianza de qué filas caen en test **no está medida.**

| Dataset simulado

No es el registro de una aseguradora real.

| El RMSE penaliza al cuadrado

El promedio está dominado por los **casos caros.**

El modelo que llevaría a producción es un
modelo lineal con once características

y esperaría un error típico de

4.288,52

Es el de **menor error de validación**
y, a la vez, el **más simple** de todo el espacio.

El modelo que llevaría a producción es un
modelo lineal con once características

y esperaría un error típico de

4.288,52

Es el de **menor error de validación**
y, a la vez, el **más simple** de todo el espacio.

Todo implementado desde cero sobre numpy, sin scikit-learn.

GRACIAS

¿Preguntas?

72.75 — Aprendizaje Automático
Instituto Tecnológico de Buenos Aires

Trabajo Práctico 1 — 26 de agosto de 2026